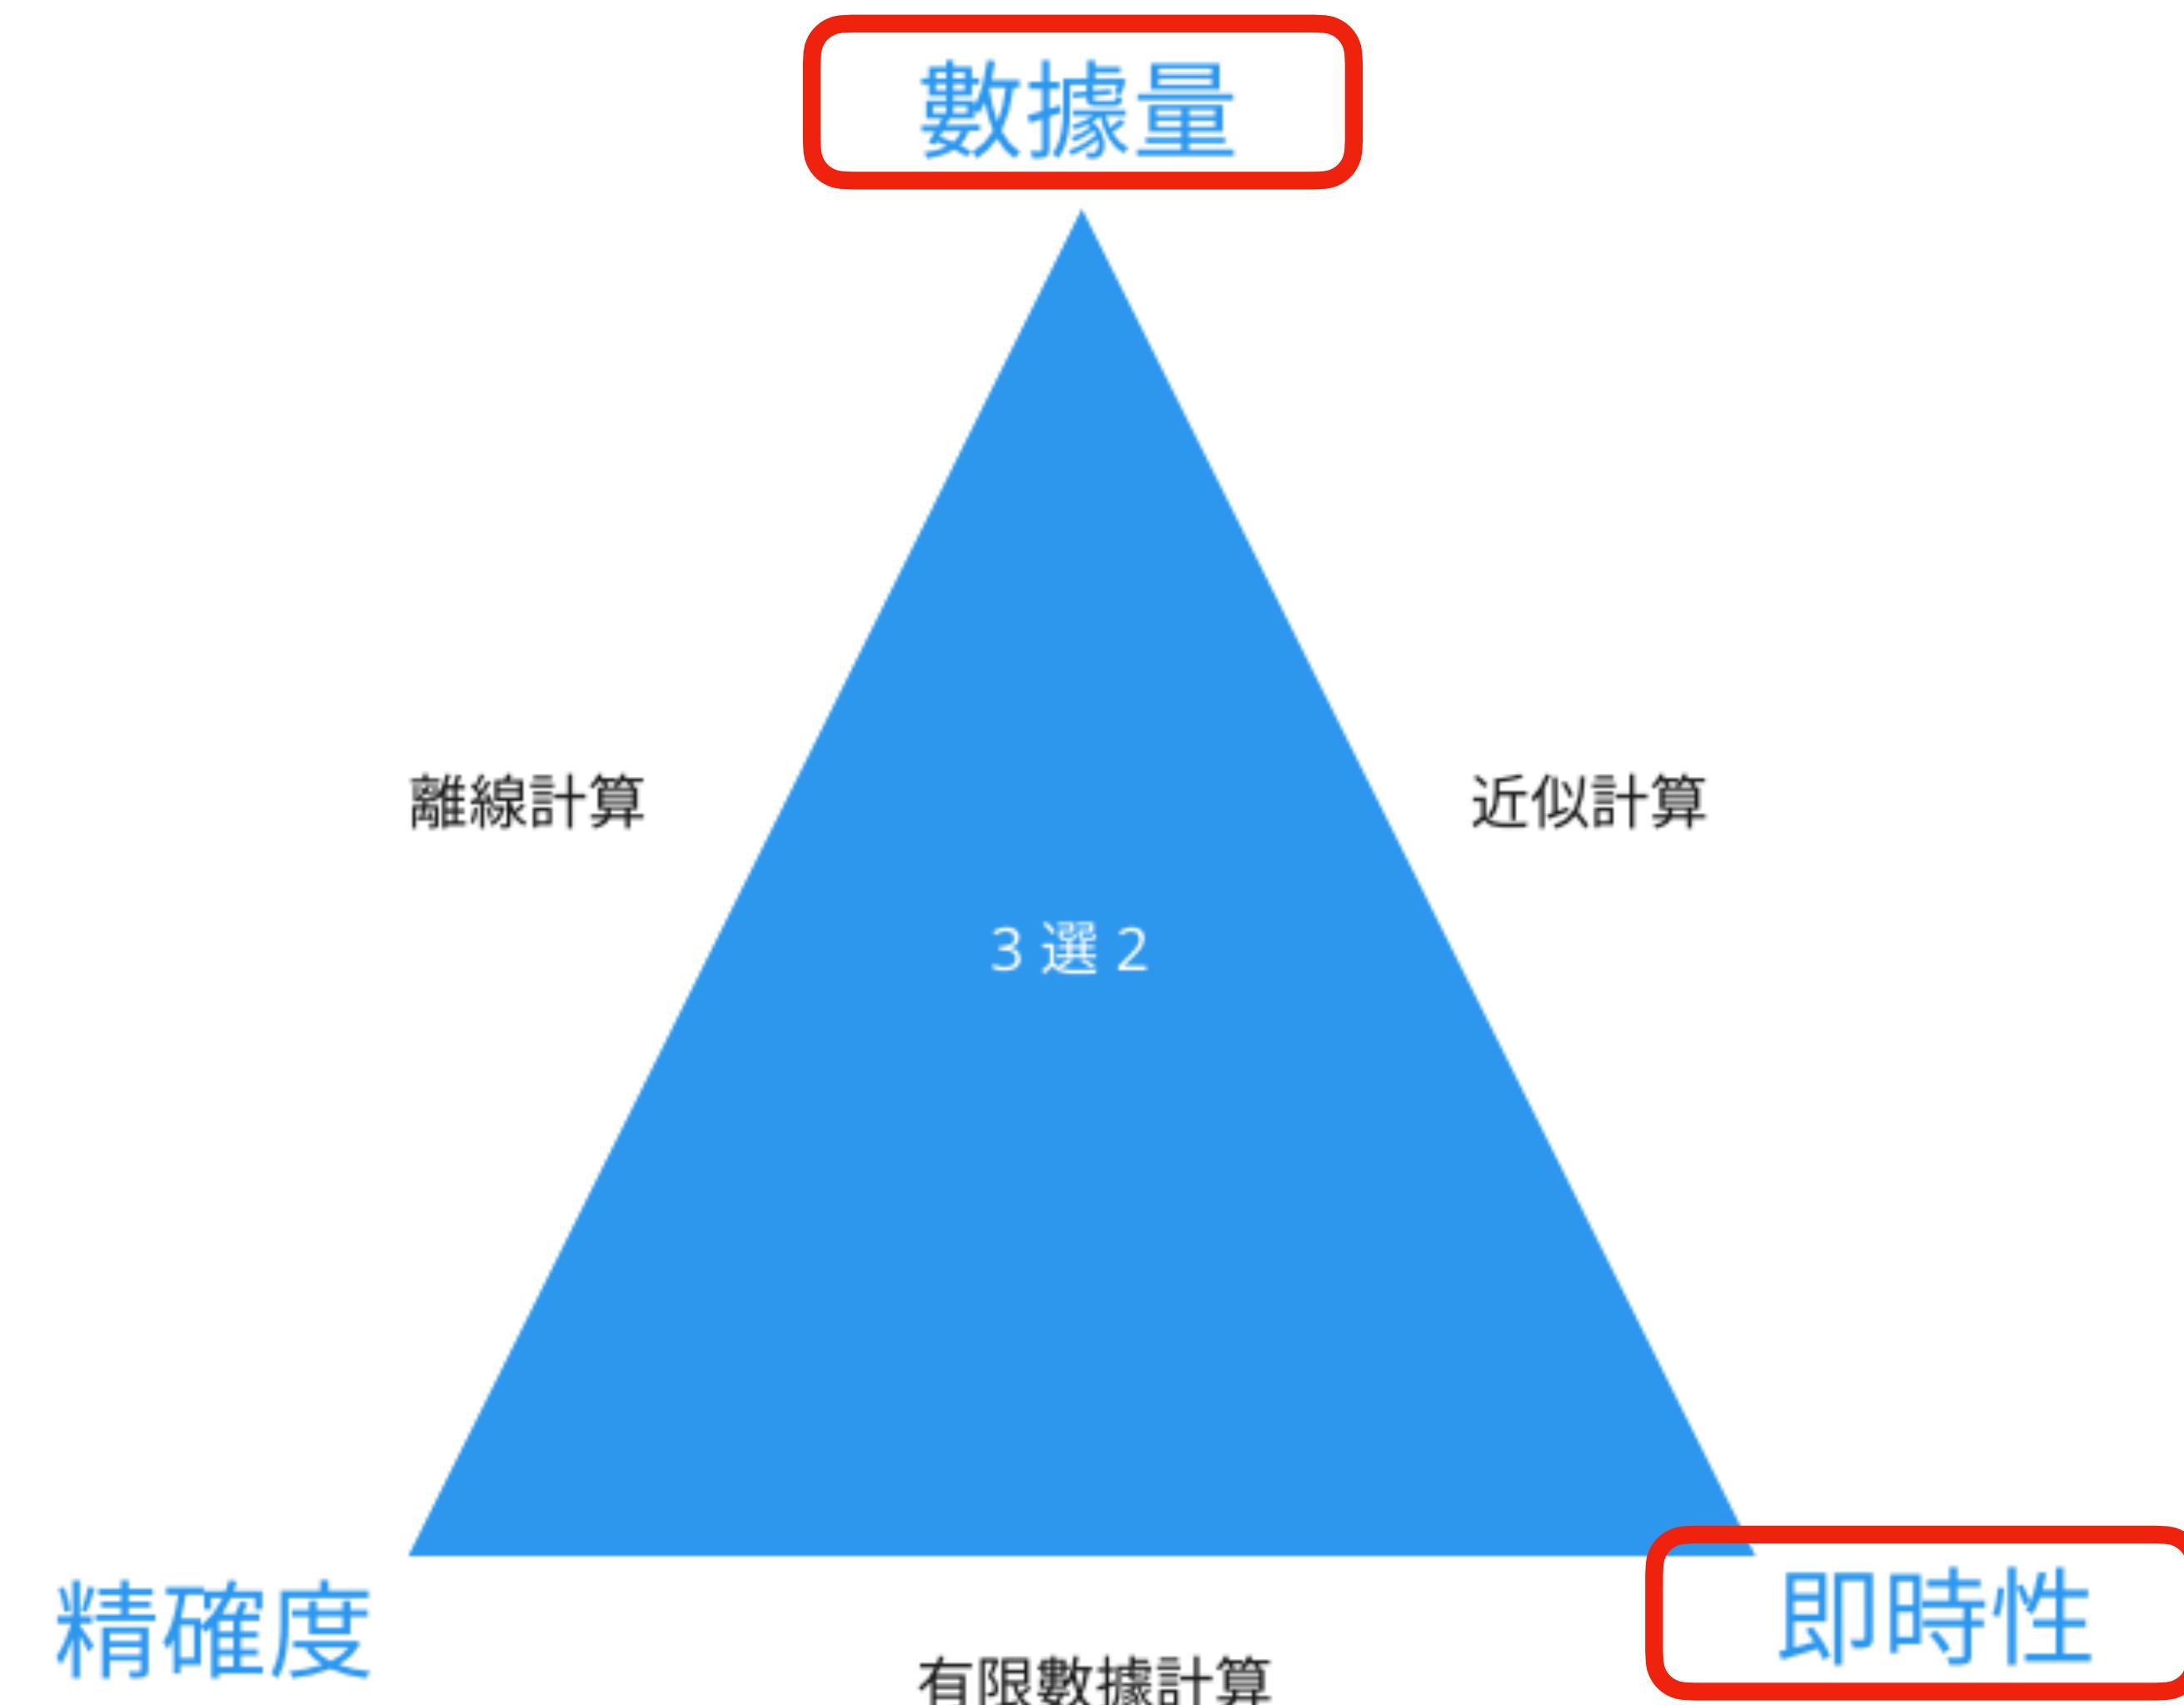


# Probabilistic Data Structure

## Data Structure For Big Data

Yuanchieh 2023/02/21

# Why We Need Probabilistic DS - Trade Off



# Agenda

- Topic 1: Membership
- Topic 2: Cardinality
- Demo
- Summary & Reference

# Topic 1: Membership

- Akamai 在 2015 年的文章中提到，觀測兩天的線上流量，有 74% 的 Cache 只被 Access 一次，此情況稱為 “One Hit Wonders”

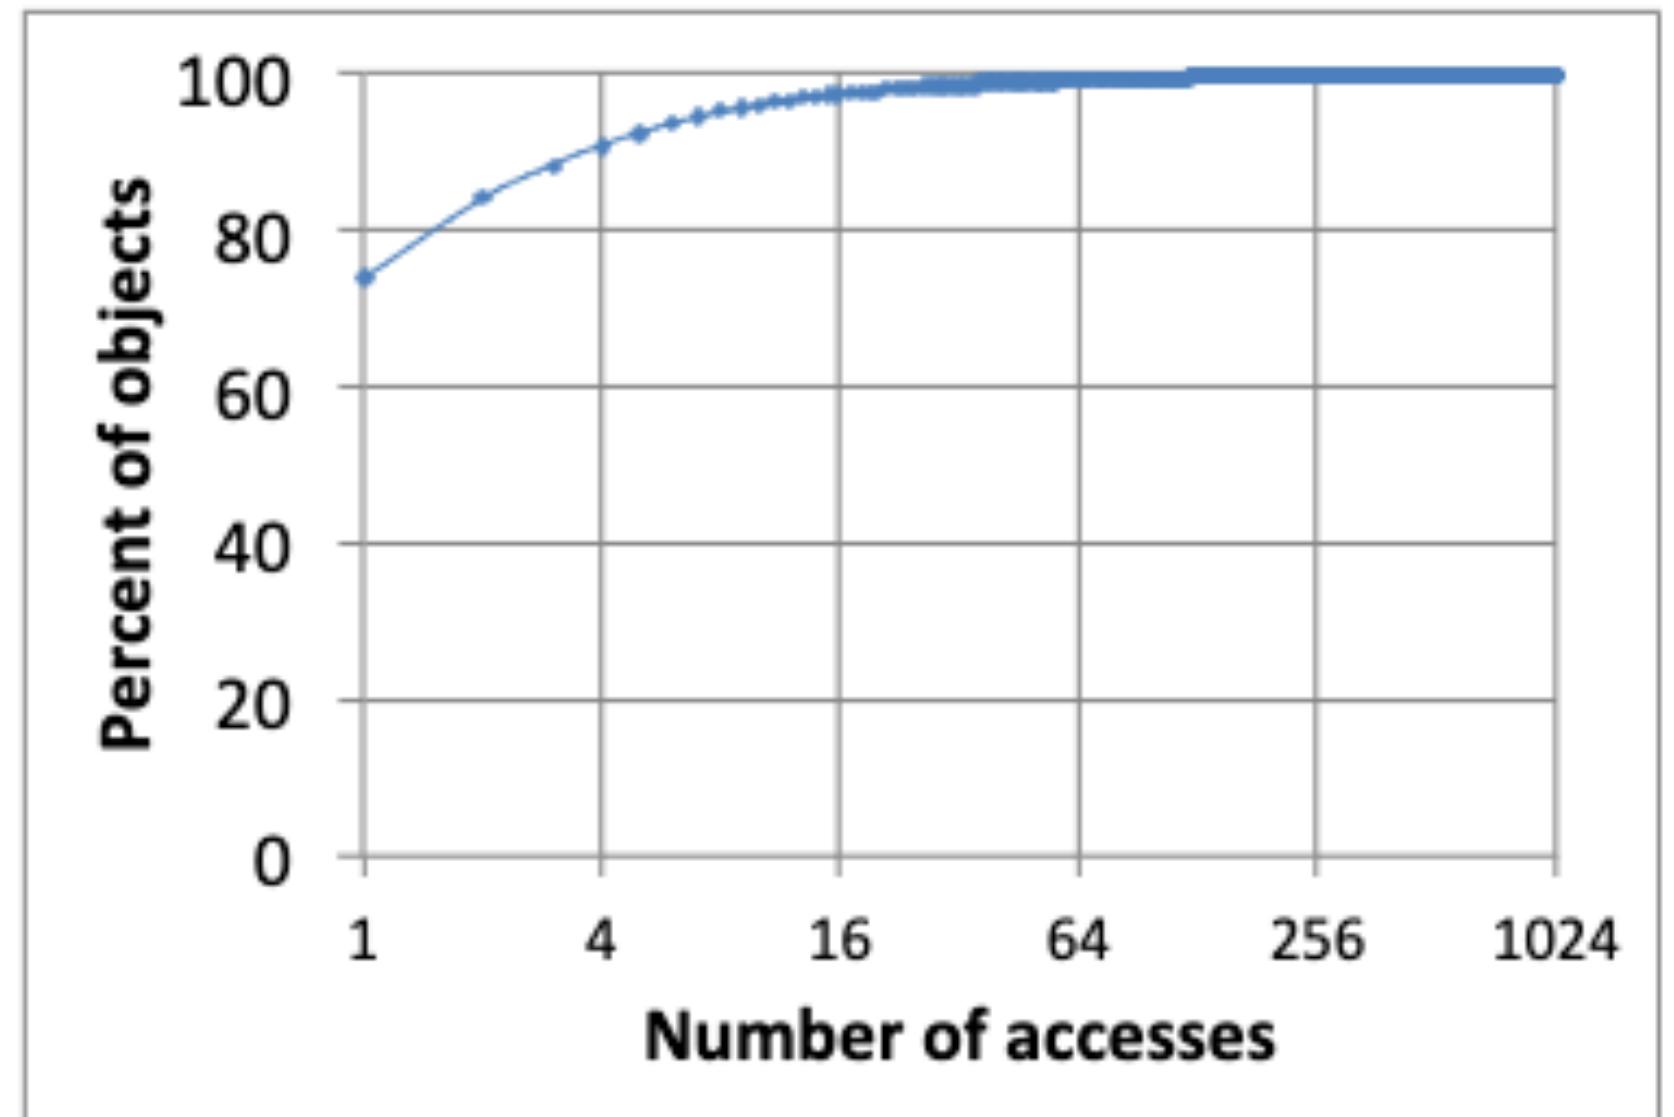


Figure 5: On a typical CDN server cluster serving web traffic over two days, 74% of the roughly 400 million objects in cache were accessed only once and 90% were accessed less than four times.

# Topic 1: Membership

- 具體需求：「輸入網址，幫我存起來，之後會詢問某網址是否有出現過」
- 系統背景：
  - 網址長度假設 200 Bytes
  - 每日網址不重複數量約 400m 筆

# Topic 1: Membership - Intuition

- Maybe HashMap ?
- {  
  "https://amazingtalker.com  "https://tw.amazingtalker.com/?gclid=Cj0KCQiAi8KfBhCuARIsADp-A55tk4RbXTHBnV9ydle0ikHP9-m82-  
  gypkrE0Io0GUFs5czVDmh7pS0aAh3PEALw\_wcB  .....  
}
- Space:  $200 \text{ Byte} * 400 \text{ m} = 80 \text{ GB!}$



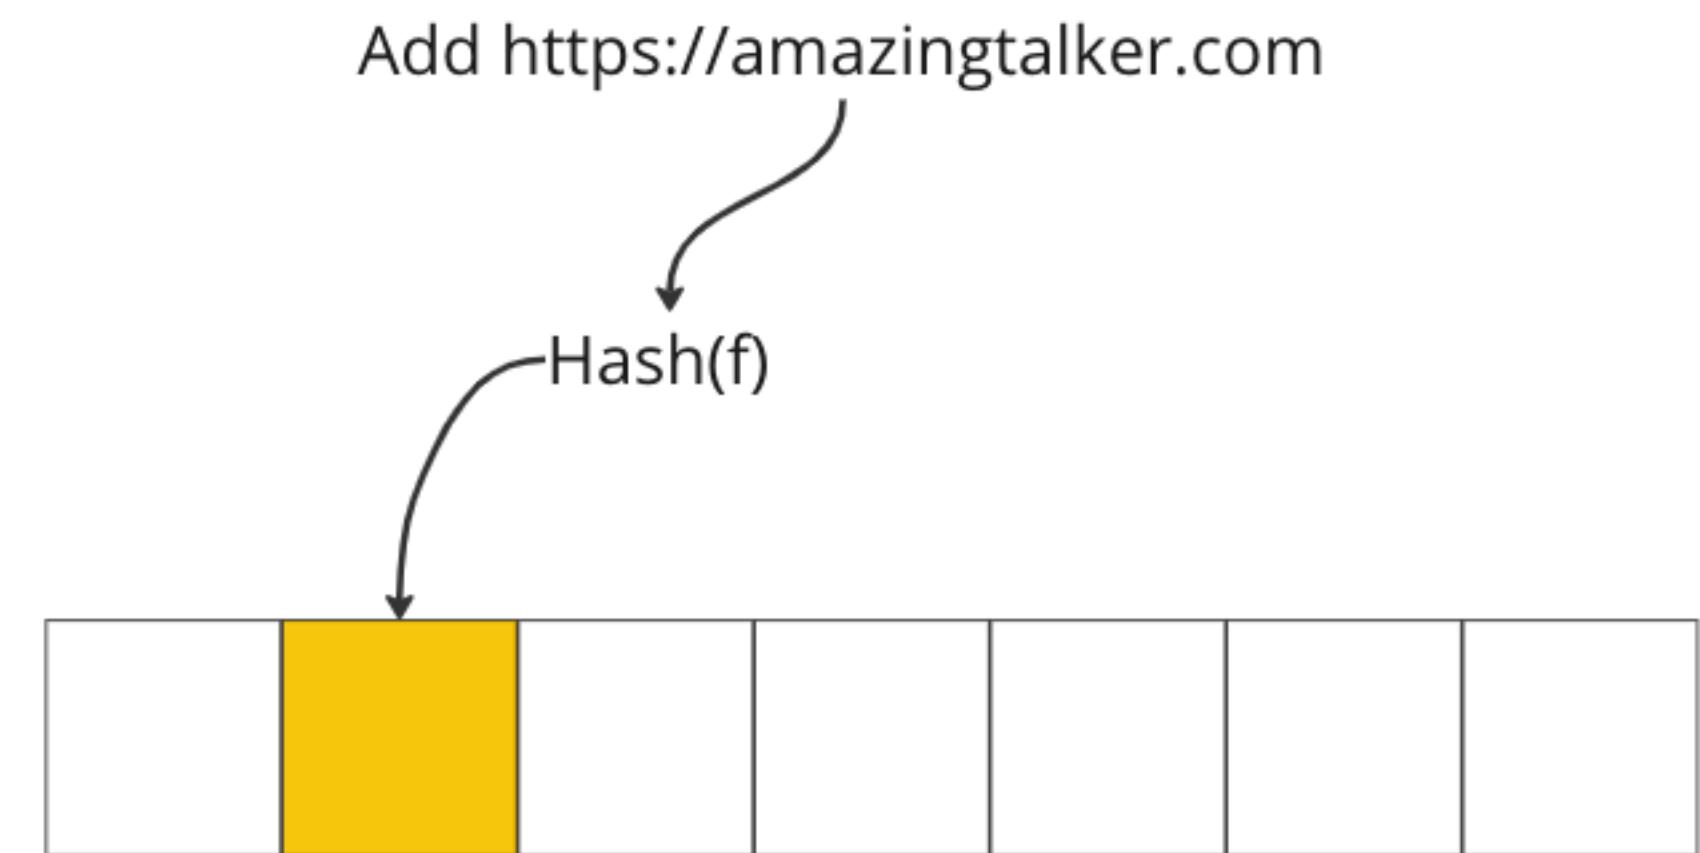
- Hashmap, I'll use a Hashmap!

# Bloom Filter

- 原本的網址太長，那就用 Hash 轉換成 int，儲存到對應的 bit array 中
- 利用 Hash same input same output 特性，下次查找到對應的 bit array 位置
- 在 bit array 足夠大以及 Hash 產生的 value 足夠分散的情況，可以有足夠的正確性

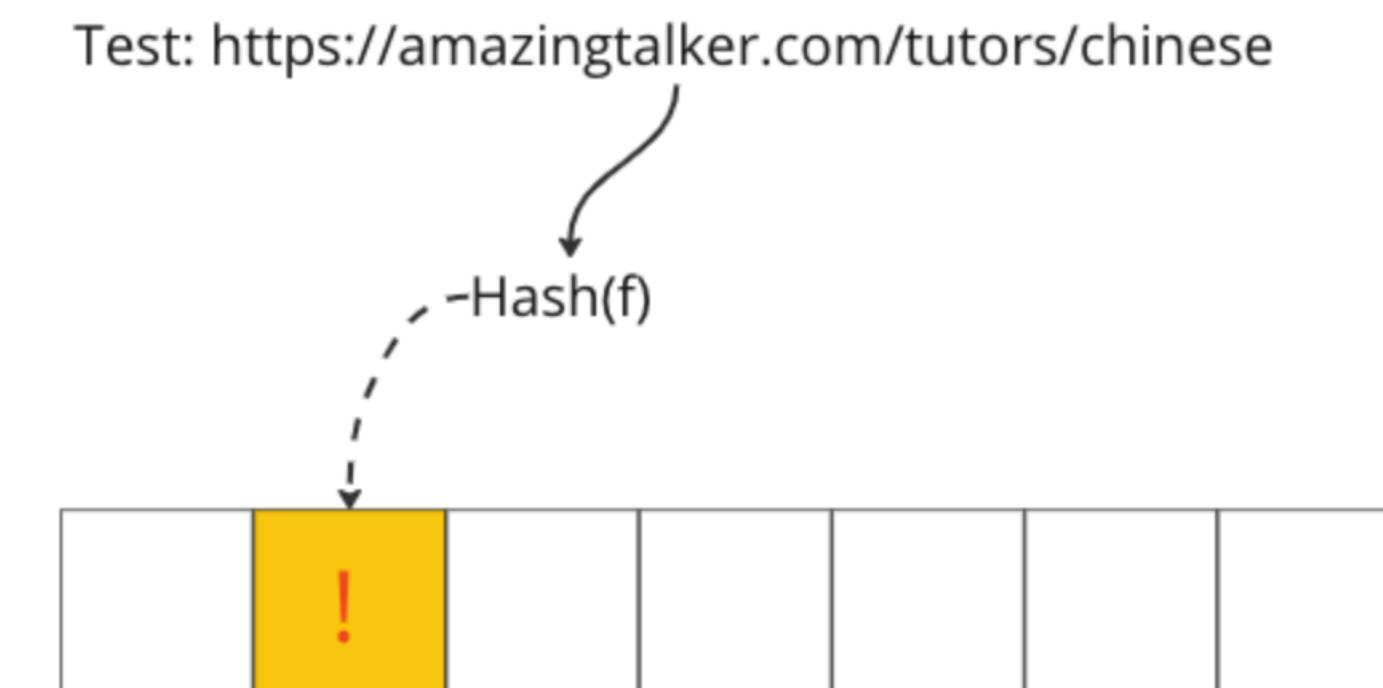
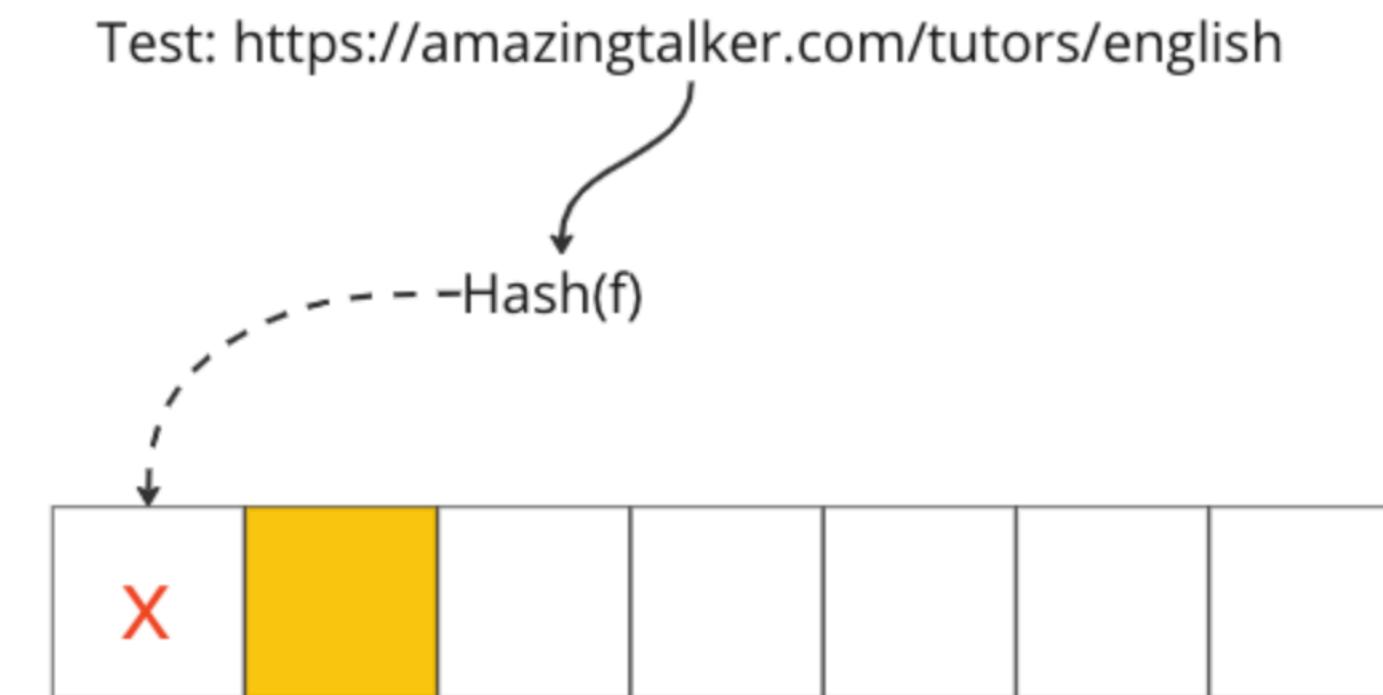
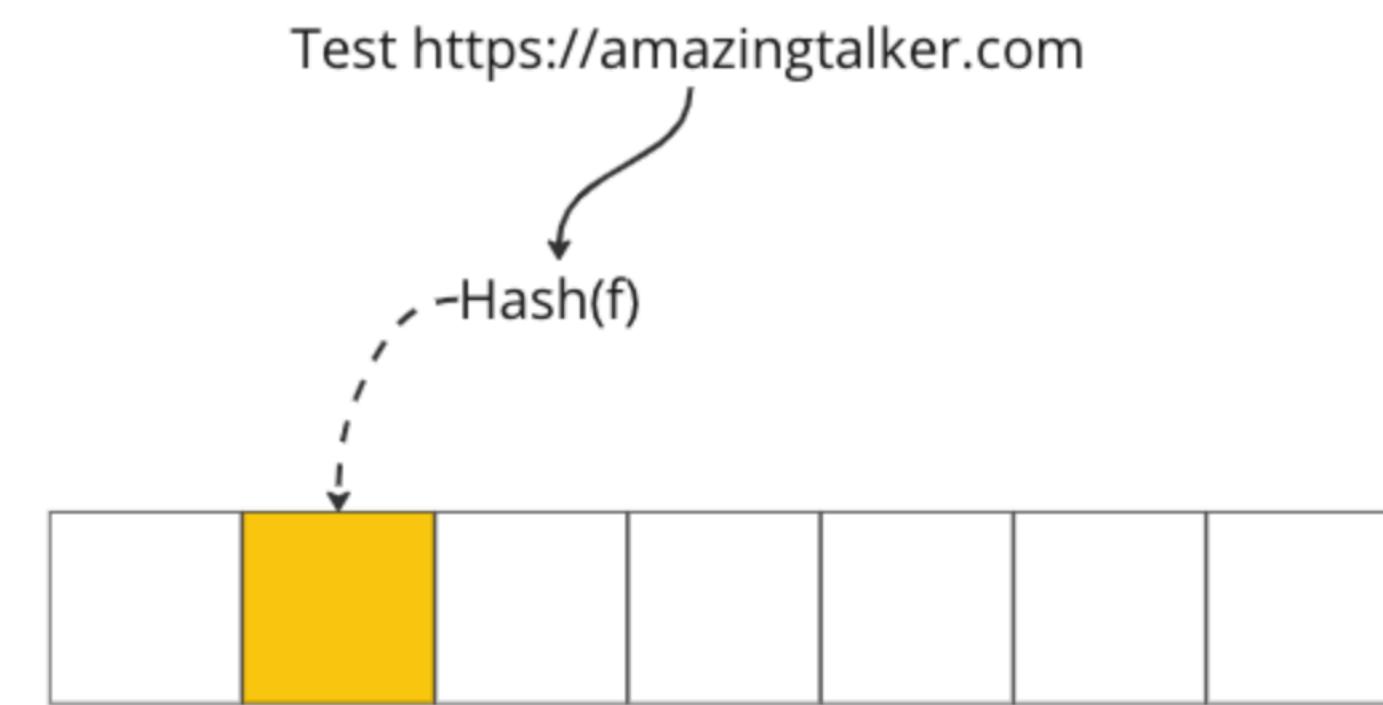
# Bloom Filter - Adding

- Adding: 將 element 透過 Hash function 轉換成 int，把對應的 bit array index 設為 true



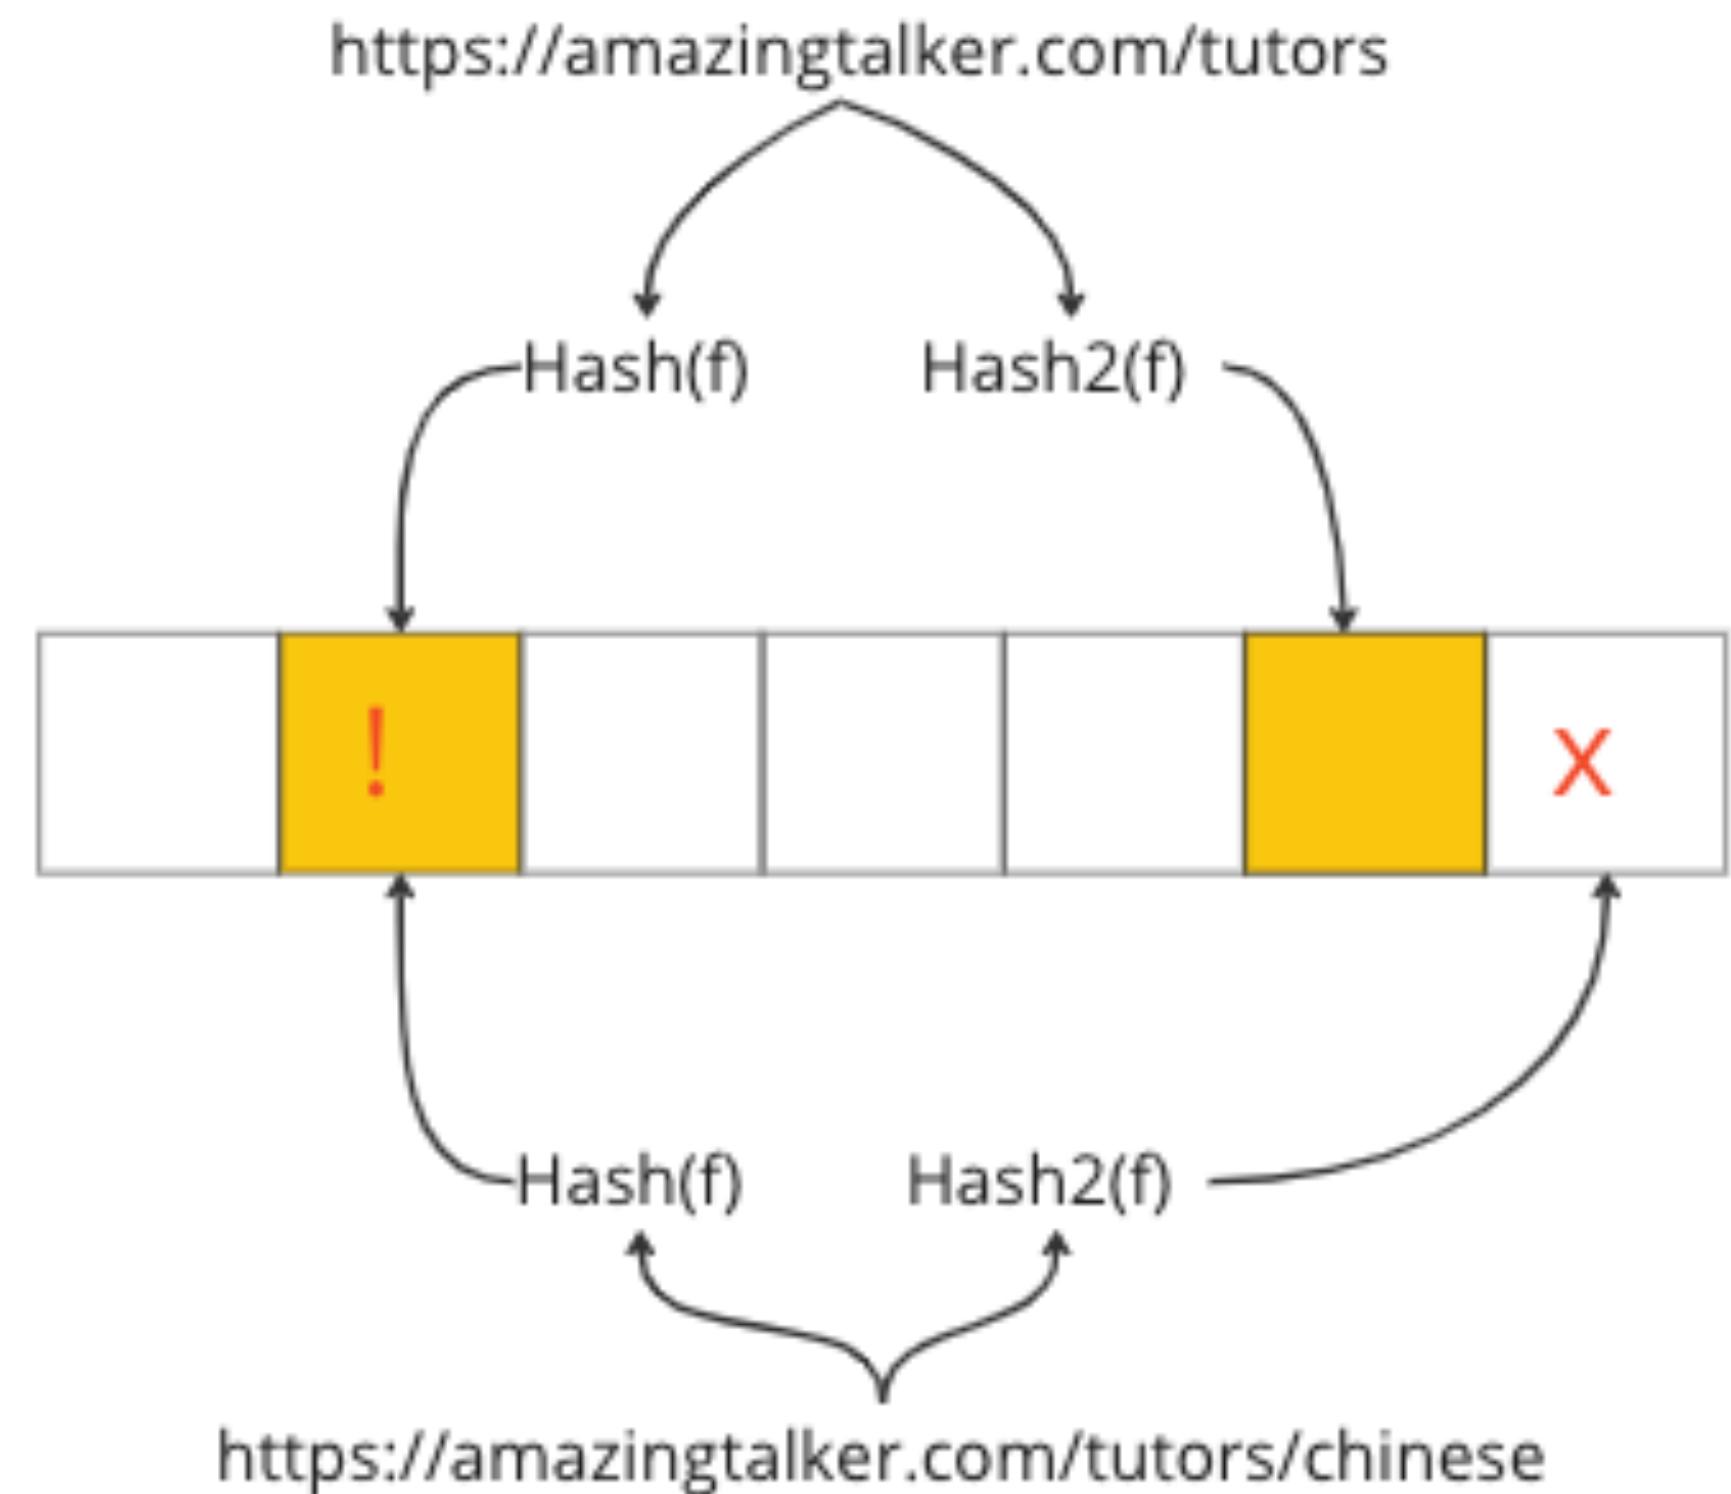
# Bloom Filter - Testing

- Testing: 檢查 element 是否出現過
  - True => “可能”出現過 (False Positive)
  - False => 一定沒有出現過



# Bloom Filter - Optimize

- Use K hash
- Use larger bit array



# Bloom Filter - Algorithm

---

**Algorithm 2.1:** Adding element to the Bloom filter

---

Input: Element  $x \in \mathbb{D}$

Input: Bloom filter with  $k$  hash functions  $\{h_i\}_{i=1}^k$

for  $i \leftarrow 1$  to  $k$  do

$j \leftarrow h_i(x)$

    BLOOMFILTER[j]  $\leftarrow 1$

---

---

**Algorithm 2.2:** Testing element in the Bloom filter

---

Input: Element  $x \in \mathbb{D}$

Input: Bloom filter with  $k$  hash functions  $\{h_i\}_{i=1}^k$

Output: False if element not found and True if element may exist

for  $i \leftarrow 1$  to  $k$  do

$j \leftarrow h_i(x)$

    if BLOOMFILTER[j]  $\neq 1$  then

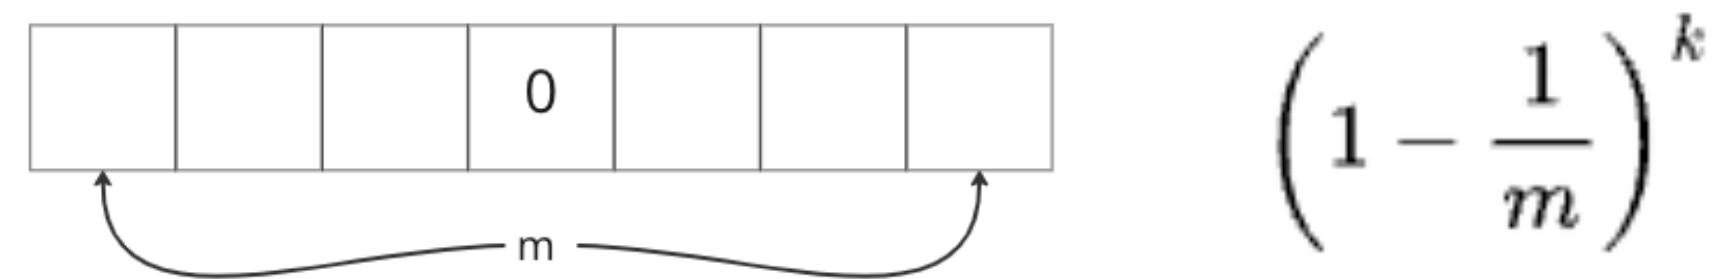
        return False

---

return True

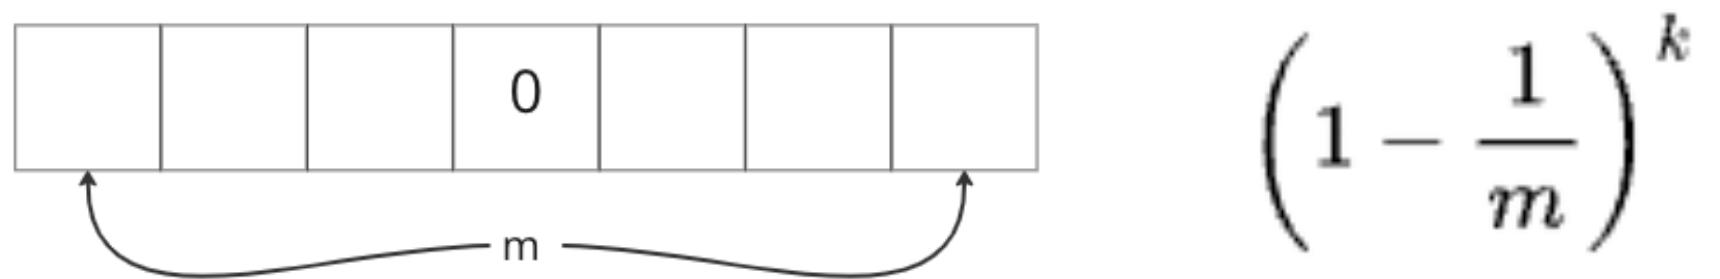
# Bloom Filter - False Positive Rate

- 加入一個 element 後 bit array 中某一個 bit 還是 0 的機率



# Bloom Filter - False Positive Rate

- 加入一個 element 後 bit array 中某一個 bit 還是 0 的機率

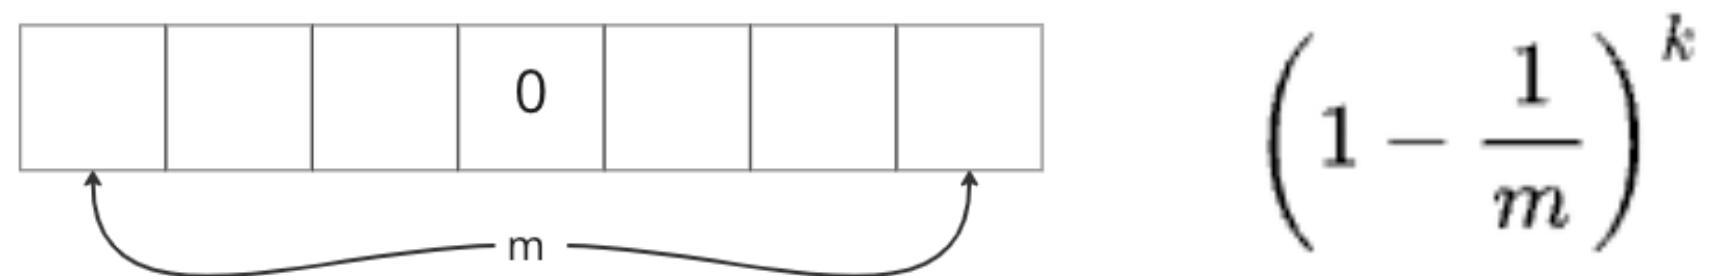


- 經過 n 輪後這個 bit 還是 0 的機率

$$\left(\left(1 - \frac{1}{m}\right)^k\right)^n = \left(1 - \frac{1}{m}\right)^{kn}$$

# Bloom Filter - False Positive Rate

- 加入一個 element 後 bit array 中某一個 bit 還是 0 的機率



- 經過 n 輪後這個 bit 還是 0 的機率

$$\left(\left(1 - \frac{1}{m}\right)^k\right)^n = \left(1 - \frac{1}{m}\right)^{kn}$$

- 第  $n+1$  輪在發生 False Positive 的機會，也就是該 bit 之前曾經被設為 1，機率剛好是排除“保持為 0 的機率”

$$probability = \left(1 - \left(1 - \frac{1}{m}\right)^{kn}\right)^k$$

# Bloom Filter - Result

- 計算所需的空间

n  
Number of items in the filter (optionally with SI units: k, M, G, T, P, E, Z, Y)

p  
Probability of false positives, fraction between 0 and 1 or a number indicating 1-in-p

m  
Number of bits in the filter (or a size with KB, KiB, MB, Mb, GiB, etc)

k  
Number of hash functions

n = 400,000,000  
p = 0.01 (1 in 100)  
**m = 4,209,081,847 (501.76MiB)**  
k = 4

80 GB => 500 MB!

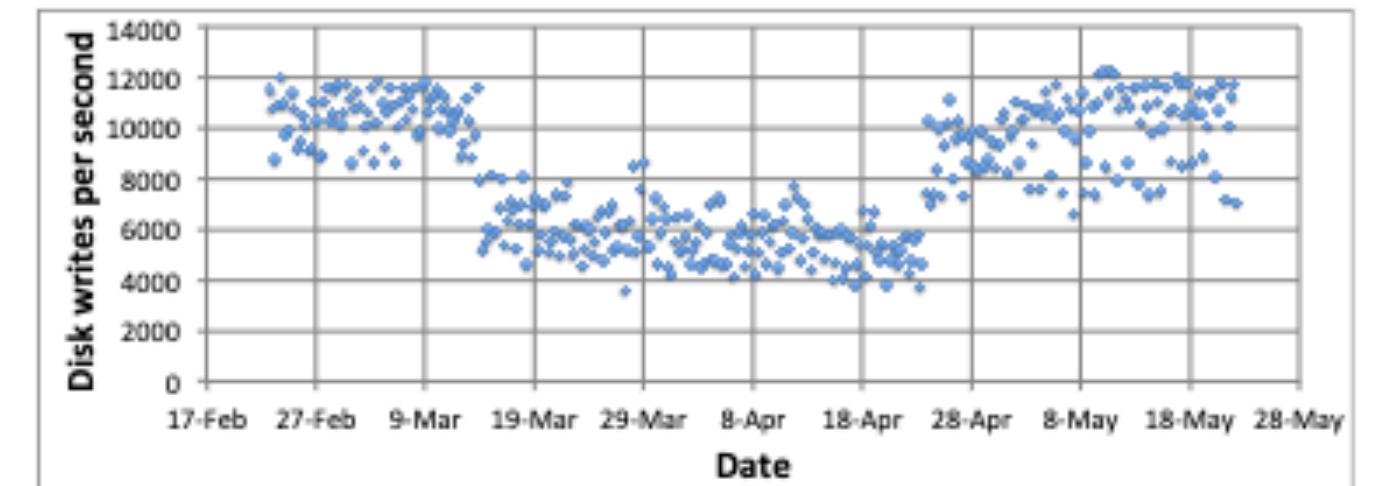
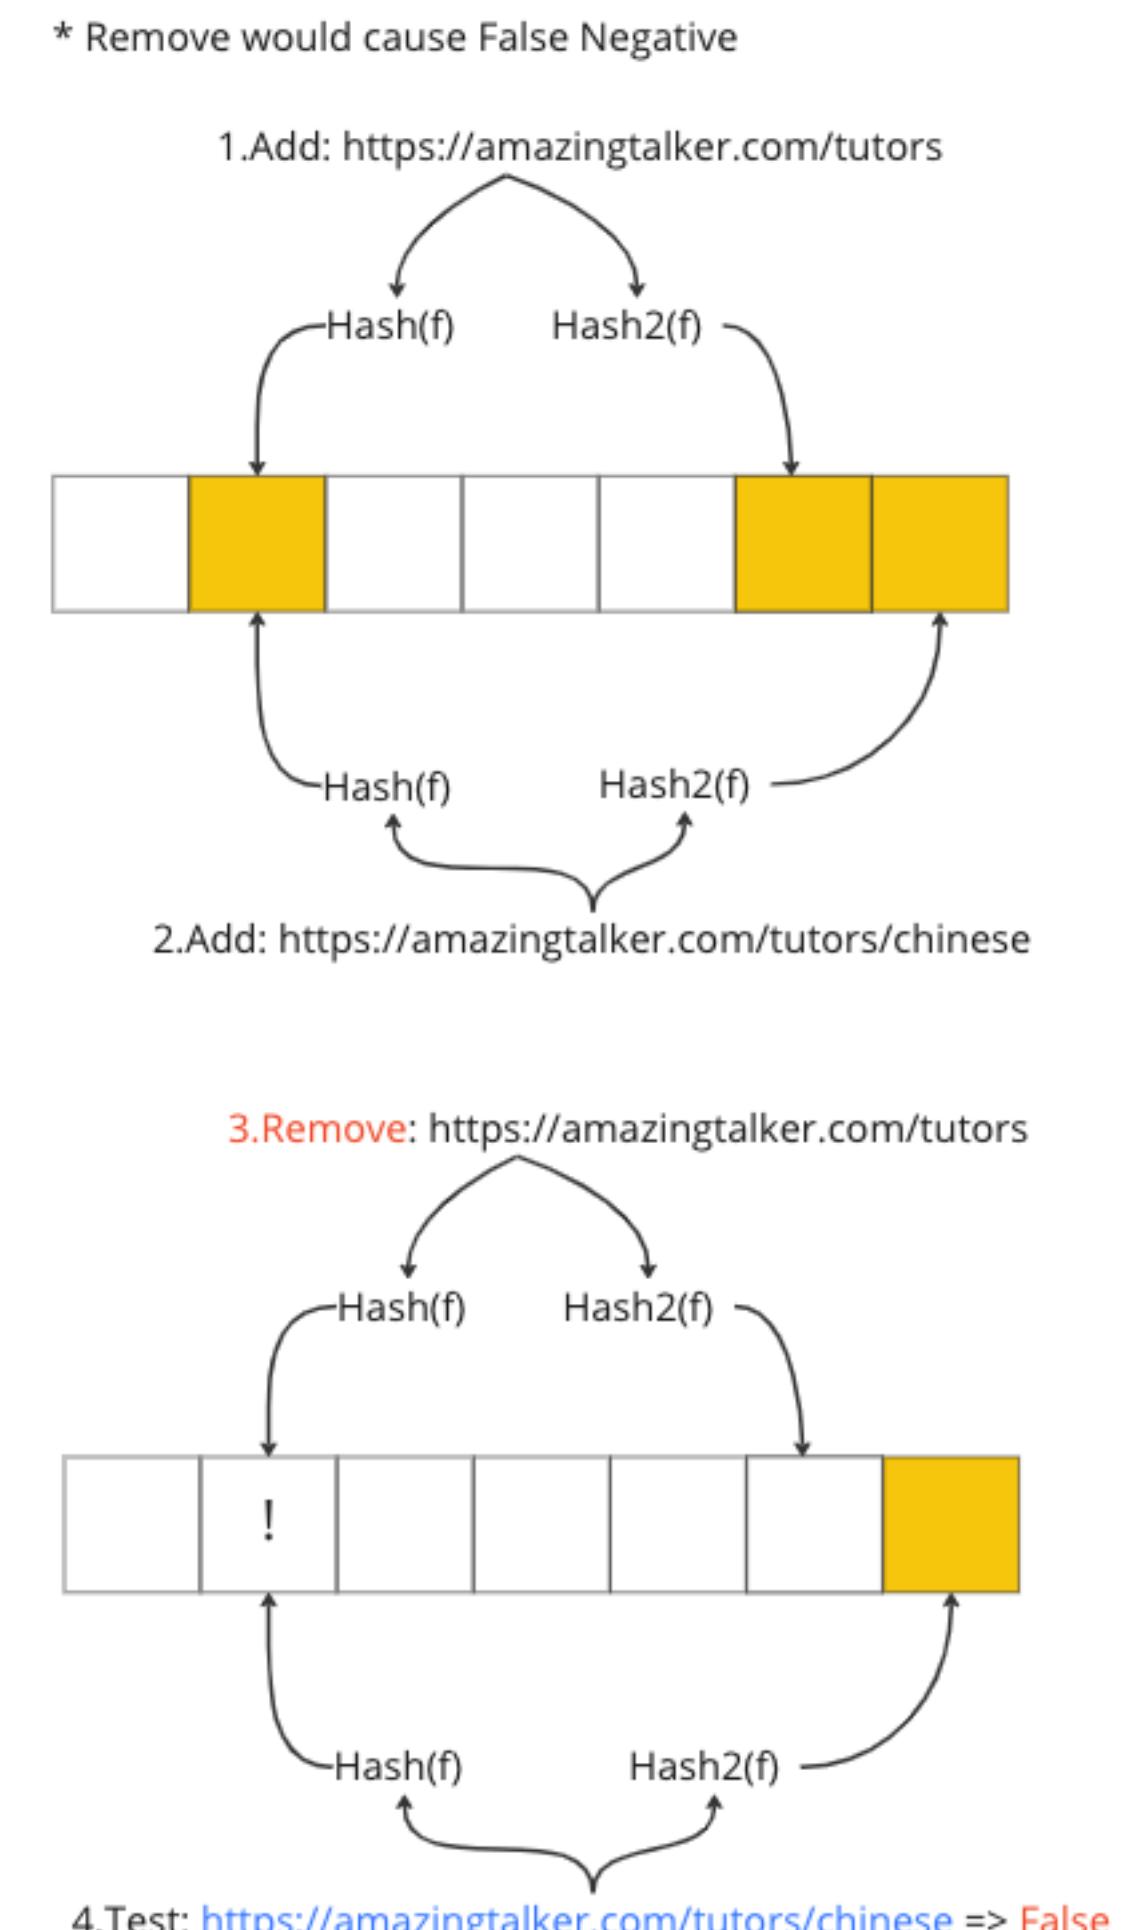


Figure 7: Turning on cache filtering decreases the rate of disk writes by nearly one half because objects accessed only once are not written to disk.

```
n = ceil(m / (-k / log(1 - exp(log(p) / k))))  
p = pow(1 - exp(-k / (m / n)), k)  
m = ceil((n * log(p)) / log(1 / pow(2, log(2))));  
k = round((m / n) * log(2));
```

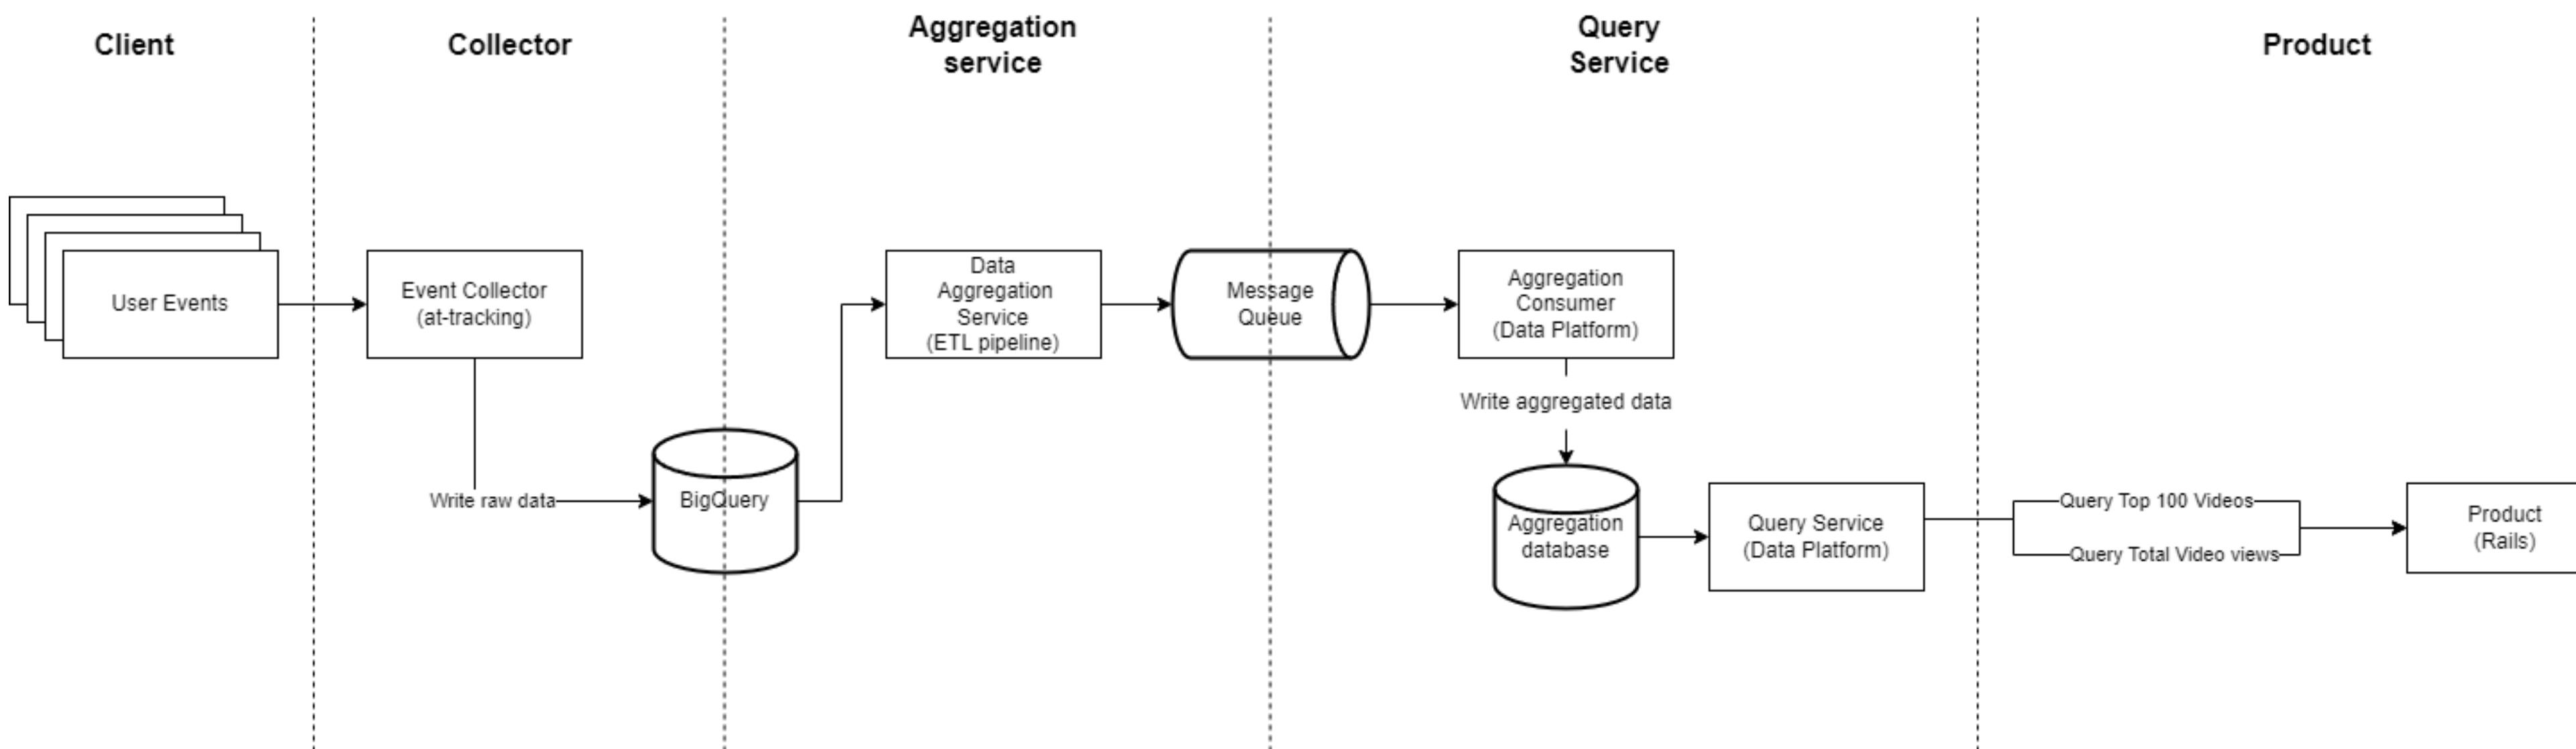
# Bloom Filter - Limitation

- 加入不能刪除，否則會出現 False Negative
  - Counting Bloom Filter
- 如果 input dataset 很大無法塞進記憶體時，效能會大幅度衰減
- bit array 無法 resize
  - resize 後需要把所有 element 重新 hash 一次找到對應的位置
- Other Solution => Quotient Filter / Cuckoo Filter



# Topic 2: Cardinality

- 短影片功能，PM 想知道每支影片的不重複瀏覽人數，目前約 [REDACTED] 影片，每部影片最高不 [REDACTED]



## Topic 2: Cardinality

- [REDACTED]
- [REDACTED] 500k 影片，每支影片不重複觀看人數暴增到 1m，想要 real time 看到不重複觀看人數的統計

# Topic 2: Cardinality - Intuition

- HashMap ?
- {  
    “video1”: {  
        “user\_1”: 1,  
        “user\_2”: 1,  
        .....  
    }  
    .....  
}

# Linear Counting

- 參考 Bloom Filter 作法，把 element hash 後寫入 bit array 對應位置
- 從 “某個 bit 經過  $n$  輪後還是 0” 的機率，數學推導等於 (陣列中為 0 的比率) ，

$$\bar{V} = \left(1 - \frac{1}{m}\right)^n \approx e^{-m \cdot n}. \quad (3.1)$$

- 推導出  $n$  (不重複個數) 的公式

$$n \approx -m \cdot \ln V. \quad (3.2)$$

---

**Algorithm 3.2:** Estimating cardinality with Linear Counting

---

**Input:** Dataset  $\mathbb{D}$

**Output:** Cardinality estimation

**LINEARCOUNTER**[ $i$ ]  $\leftarrow 0$ ,  $i = 0 \dots m - 1$

**for**  $x \in \mathbb{D}$  **do**

**Add**( $x$ , LINEARCOUNTER)

$Z \leftarrow \sum_{i=0 \dots m-1} \text{count}(\text{LINEARCOUNTER}[i] = 0)$

**return**  $\lfloor -m \cdot \ln \frac{Z}{m} \rfloor$

---

# Linear Counting

- 特性
  - 適合小的資料集
  - 資料儲存空間跟輸入範圍成線性關係 (Linear)

# LogLog 與他的家族

- LogLog
- SuperLogLog
- HyperLogLog
- HyperLogLog++

# LogLog - 概念

- 玩一個擲公正硬幣的遊戲
  - 如果是 H => 繼續
  - 如果是 T => 結束
- 今天出現 “HHHT” 的機率是 1/16
  - 換句話說 “平均擲 16 次出現 1 次”
- simulate: <https://gist.github.com/sj82516/41f2ef0cd235089993502c86b65d142b>

# LogLog - 概念

- 玩一個擲公正硬幣的遊戲
  - 如果是 H => 繼續
  - 如果是 T => 結束
- 今天出現 “HHHT” 的機率是 1/16
  - 換句話說 “平均擲 16 次出現 1 次”
  - 在換句話說 “出現 HHHT 前會出現 15 個不同的結果”
  - 公式 :  $2^{(\text{leading H count}+1)}$
- simulate: <https://gist.github.com/sj82516/41f2ef0cd235089993502c86b65d142b>

# LogLog - 概念

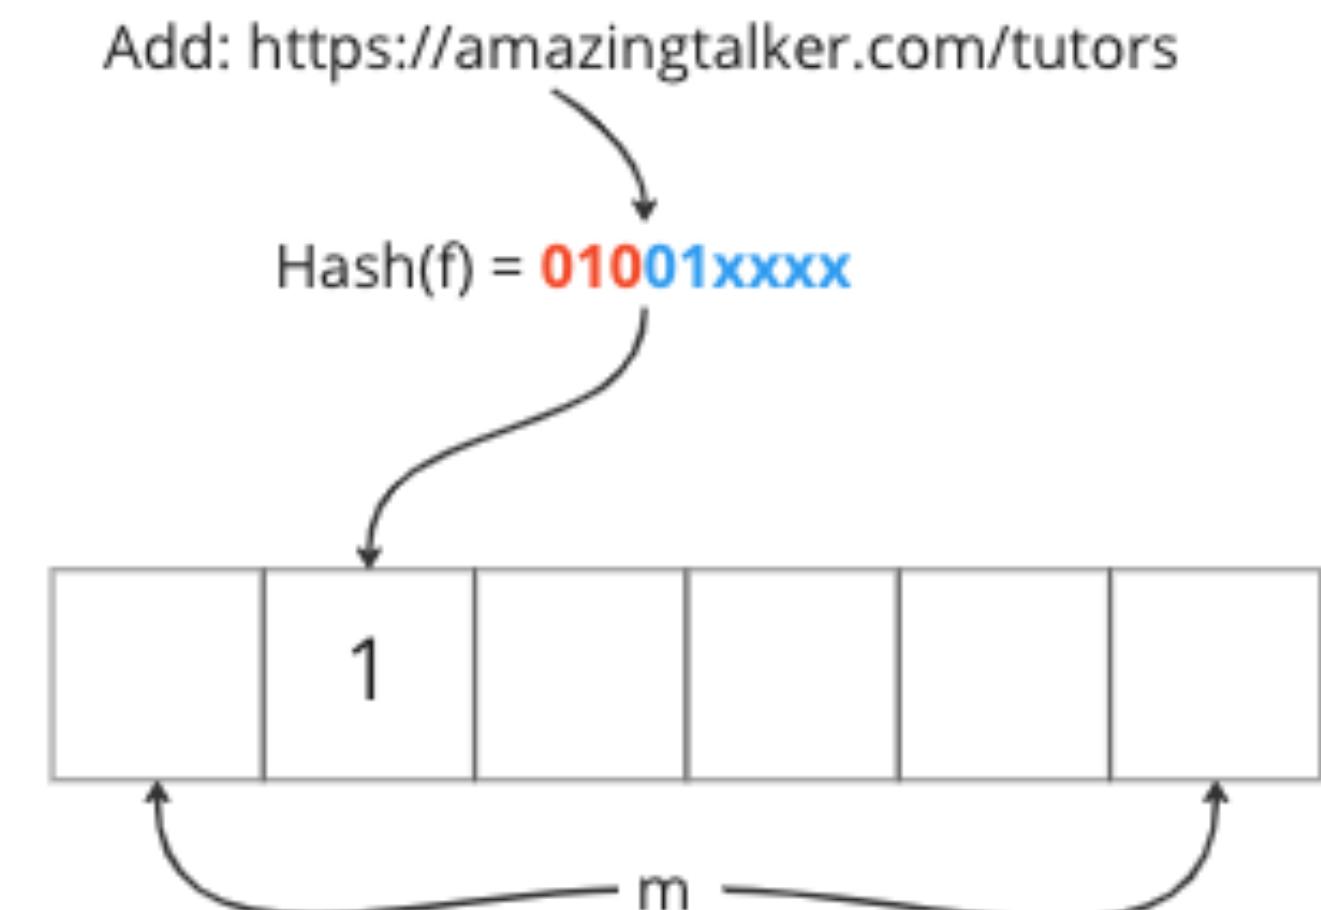
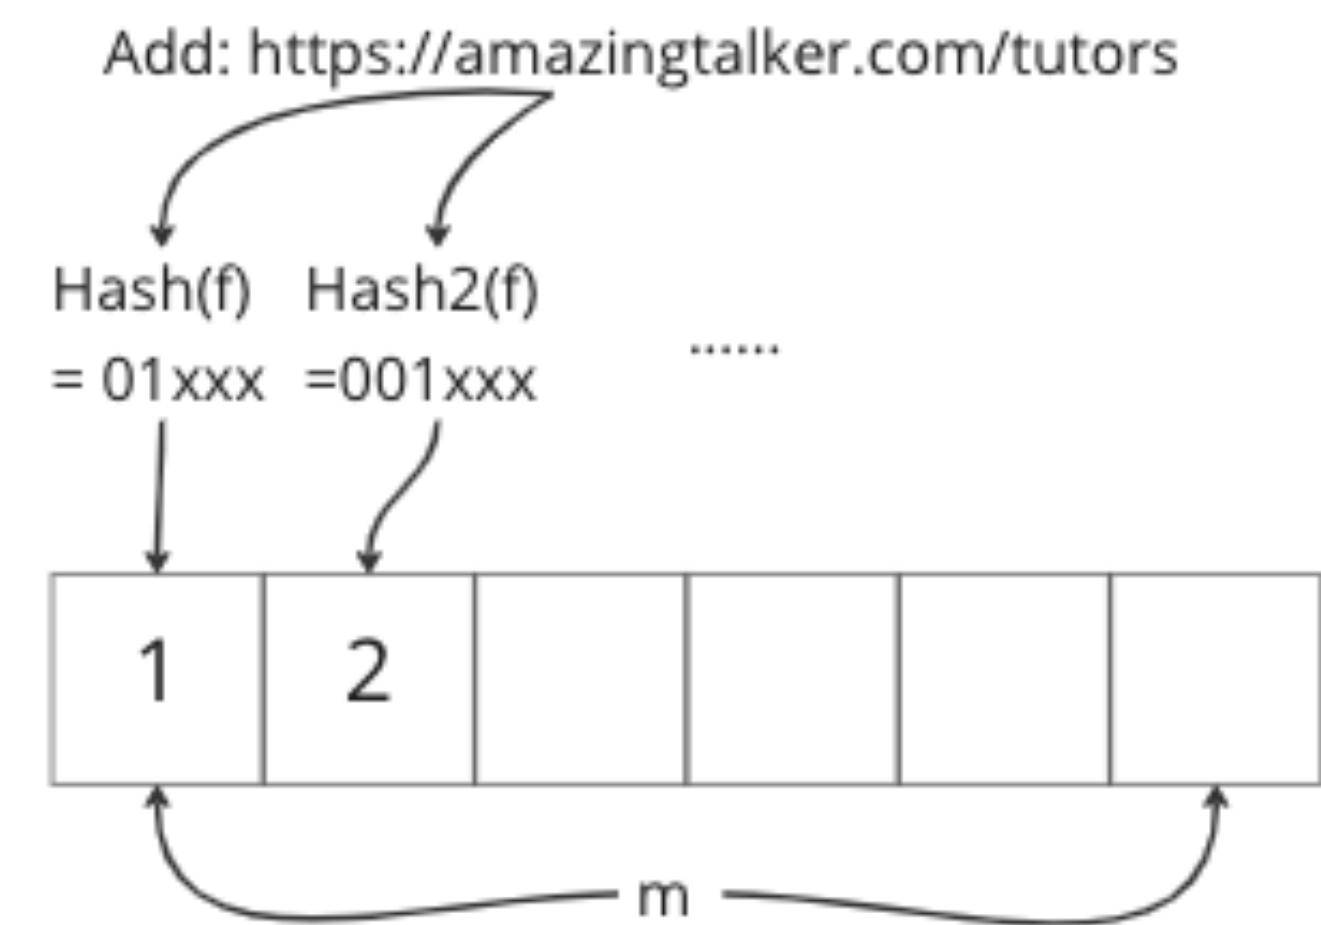
- element 經過 Hash function 輸出 int，轉成 binary format，把  $0 = H / 1 = T$ ，用 Leading 0 count 來推算 cardinality
  - ex. 0010101.....
- 問題
  - 太過於運氣性質，被偏差值所影響
  - 預估都是 2 的次方倍，到後面每一層都差距很大

$$2^{(\text{leading } H \text{ count} + 1)}$$

# LogLog - 再分散

- 解法

- Hash m 次在更近一步分散，最後取平均
- 但取 Hash 會需要耗費 CPU 資源，改用前幾個 bit 決定對應的 counter，剩餘 bit 才用來預估



# LogLog - 演算法

- 演算法

---

**Algorithm 3.7:** Estimating cardinality with LogLog

---

Input: Dataset  $\mathbb{D}$

Input: Array of  $m$  LogLog counters with hash function  $h$

Output: Cardinality estimation

$\text{COUNTER}[j] \leftarrow 0, j = 0 \dots m - 1$

for  $x \in \mathbb{D}$  do

$i \leftarrow h(x) := (i_0 i_1 \dots i_{M-1})_2, i_k \in \{0, 1\}$   
 $j \leftarrow (i_0 i_1 \dots i_{p-1})_2$   
 $r \leftarrow \text{rank}((i_p i_{p+1} \dots i_{M-1})_2)$   
 $\text{COUNTER}[j] \leftarrow \max(\text{COUNTER}[j], r)$

$R \leftarrow \frac{1}{m} \sum_{k=0}^{m-1} \text{COUNTER}[j]$

return  $\alpha_m \cdot m \cdot 2^R$

---

- 誤差

$$\hat{\delta} \approx \frac{1.3}{\sqrt{m}}. \quad (3.12)$$

# LogLog - 實際所需空間

- Counter 只需要儲存 Leading 0 的 max count
  - 假設輸入範圍是  $2^{64}$ ，轉成 binary format  
10010...0 (64 bit)
  - 儲存 64 只需要 7 bit!

# LogLog - 實際所需空間

- Counter 只需要儲存 Leading 0 的 max count
  - 假設輸入範圍是  $2^{64}$ ，轉成 binary format  
10010...0 (64 bit)
  - 儲存 64 只需要 7 bit!
  - 計算 leading 0 count，數值範圍 0~64

# LogLog - 實際所需空間

- Counter 只需要儲存 Leading 0 的 max count
  - 假設輸入範圍是  $2^{64}$ ，轉成 binary format  
10010...0 (64 bit)
  - 計算 leading 0 count ，數值範圍 0~64
  - 輸入範圍與儲存空間的關係就是  $\log(\log(2^{64})) = 7$
- 總共有 m 個 counter，total size =  $6 * m$  bit!

# LogLog - 實際所需空間



pmitf.com

# SuperLogLog

- 在  $m$  個 bucket 中，排序只取前 70% 後平均
- 誤差

$$\varepsilon = \frac{1.05}{\sqrt{m}}$$

# HyperLogLog

- 改良方向
  - 當輸入很小時，改用 Linear Counting
  - 超過一個閥值，改用 LogLog
  - 逼近 Hash value 上限 (32 bit)，改用另一個公式
  - 不用平均，改用其他的公式彙整
  - 誤差

$$\frac{1.04}{\sqrt{m}}$$

---

**Algorithm 3.8:** Estimating cardinality with HyperLogLog

---

**Input:** Dataset  $\mathbb{D}$   
**Input:** Array of  $m$  LogLog counters with hash function  $h$   
**Output:** Cardinality estimation  
 $\text{COUNTER}[j] \leftarrow 0, j = 0 \dots m - 1$   
**for**  $x \in \mathbb{D}$  **do**  
     $i \leftarrow h(x) := (i_0 i_1 \dots i_{31})_2, i_k \in \{0, 1\}$   
     $j \leftarrow (i_0 i_1 \dots i_{p-1})_2$   
     $r \leftarrow \text{rank}((i_p i_{p+1} \dots i_{31})_2)$   
     $\text{COUNTER}[j] \leftarrow \max(\text{COUNTER}[j], r)$   
 $R \leftarrow \sum_{k=0}^{m-1} 2^{-\text{COUNTER}[j]}$   
 $\hat{n} = \alpha_m \cdot m^2 \cdot \frac{1}{R}$   
 $n \leftarrow \hat{n}$   
**if**  $\hat{n} \leq \frac{5}{2}m$  **then**  
     $Z \leftarrow \underset{j=0 \dots m-1}{\text{count}}(\text{COUNTER}[j] = 0)$   
    **if**  $Z \neq 0$  **then**  
         $n \leftarrow m \cdot \log\left(\frac{m}{Z}\right)$   
**else if**  $\hat{n} > \frac{1}{30}2^{32}$  **then**  
         $n \leftarrow -2^{32} \cdot \log\left(1 - \frac{n}{2^{32}}\right)$   
**return**  $n$

---

# HyperLogLog++

- 改良方向
  - 把 Hash 範圍從 32 bit 改成 64 bit
  - 基於經驗調整參數與修正偏差

---

**Algorithm 3.10:** Estimating cardinality with HyperLogLog++

---

**Input:** Dataset  $\mathbb{D}$

**Input:** Array of  $m$  LogLog counters with hash function  $h$

**Output:** Cardinality estimation

$\text{COUNTER}[j] \leftarrow 0, j = 0 \dots m - 1$

**for**  $x \in \mathbb{D}$  **do**

$i \leftarrow h(x) := (i_0 i_1 \dots i_{63})_2, i_k \in \{0, 1\}$   
 $j \leftarrow (i_0 i_1 \dots i_{p-1})_2$   
 $r \leftarrow \text{rank}((i_p i_{p+1} \dots i_{63})_2)$   
 $\text{COUNTER}[j] \leftarrow \max(\text{COUNTER}[j], r)$

$R \leftarrow \sum_{k=0}^{m-1} 2^{-\text{COUNTER}[j]}$

$\hat{n} = \alpha_m \cdot m^2 \cdot \frac{1}{R}$

$n \leftarrow \hat{n}$

**if**  $\hat{n} \leq 5m$  **then**

$n \leftarrow \text{CorrectBias}(\hat{n})$

$Z \leftarrow \sum_{j=0 \dots m-1} \text{count}(\text{COUNTER}[j] = 0)$

**if**  $Z \neq 0$  **then**

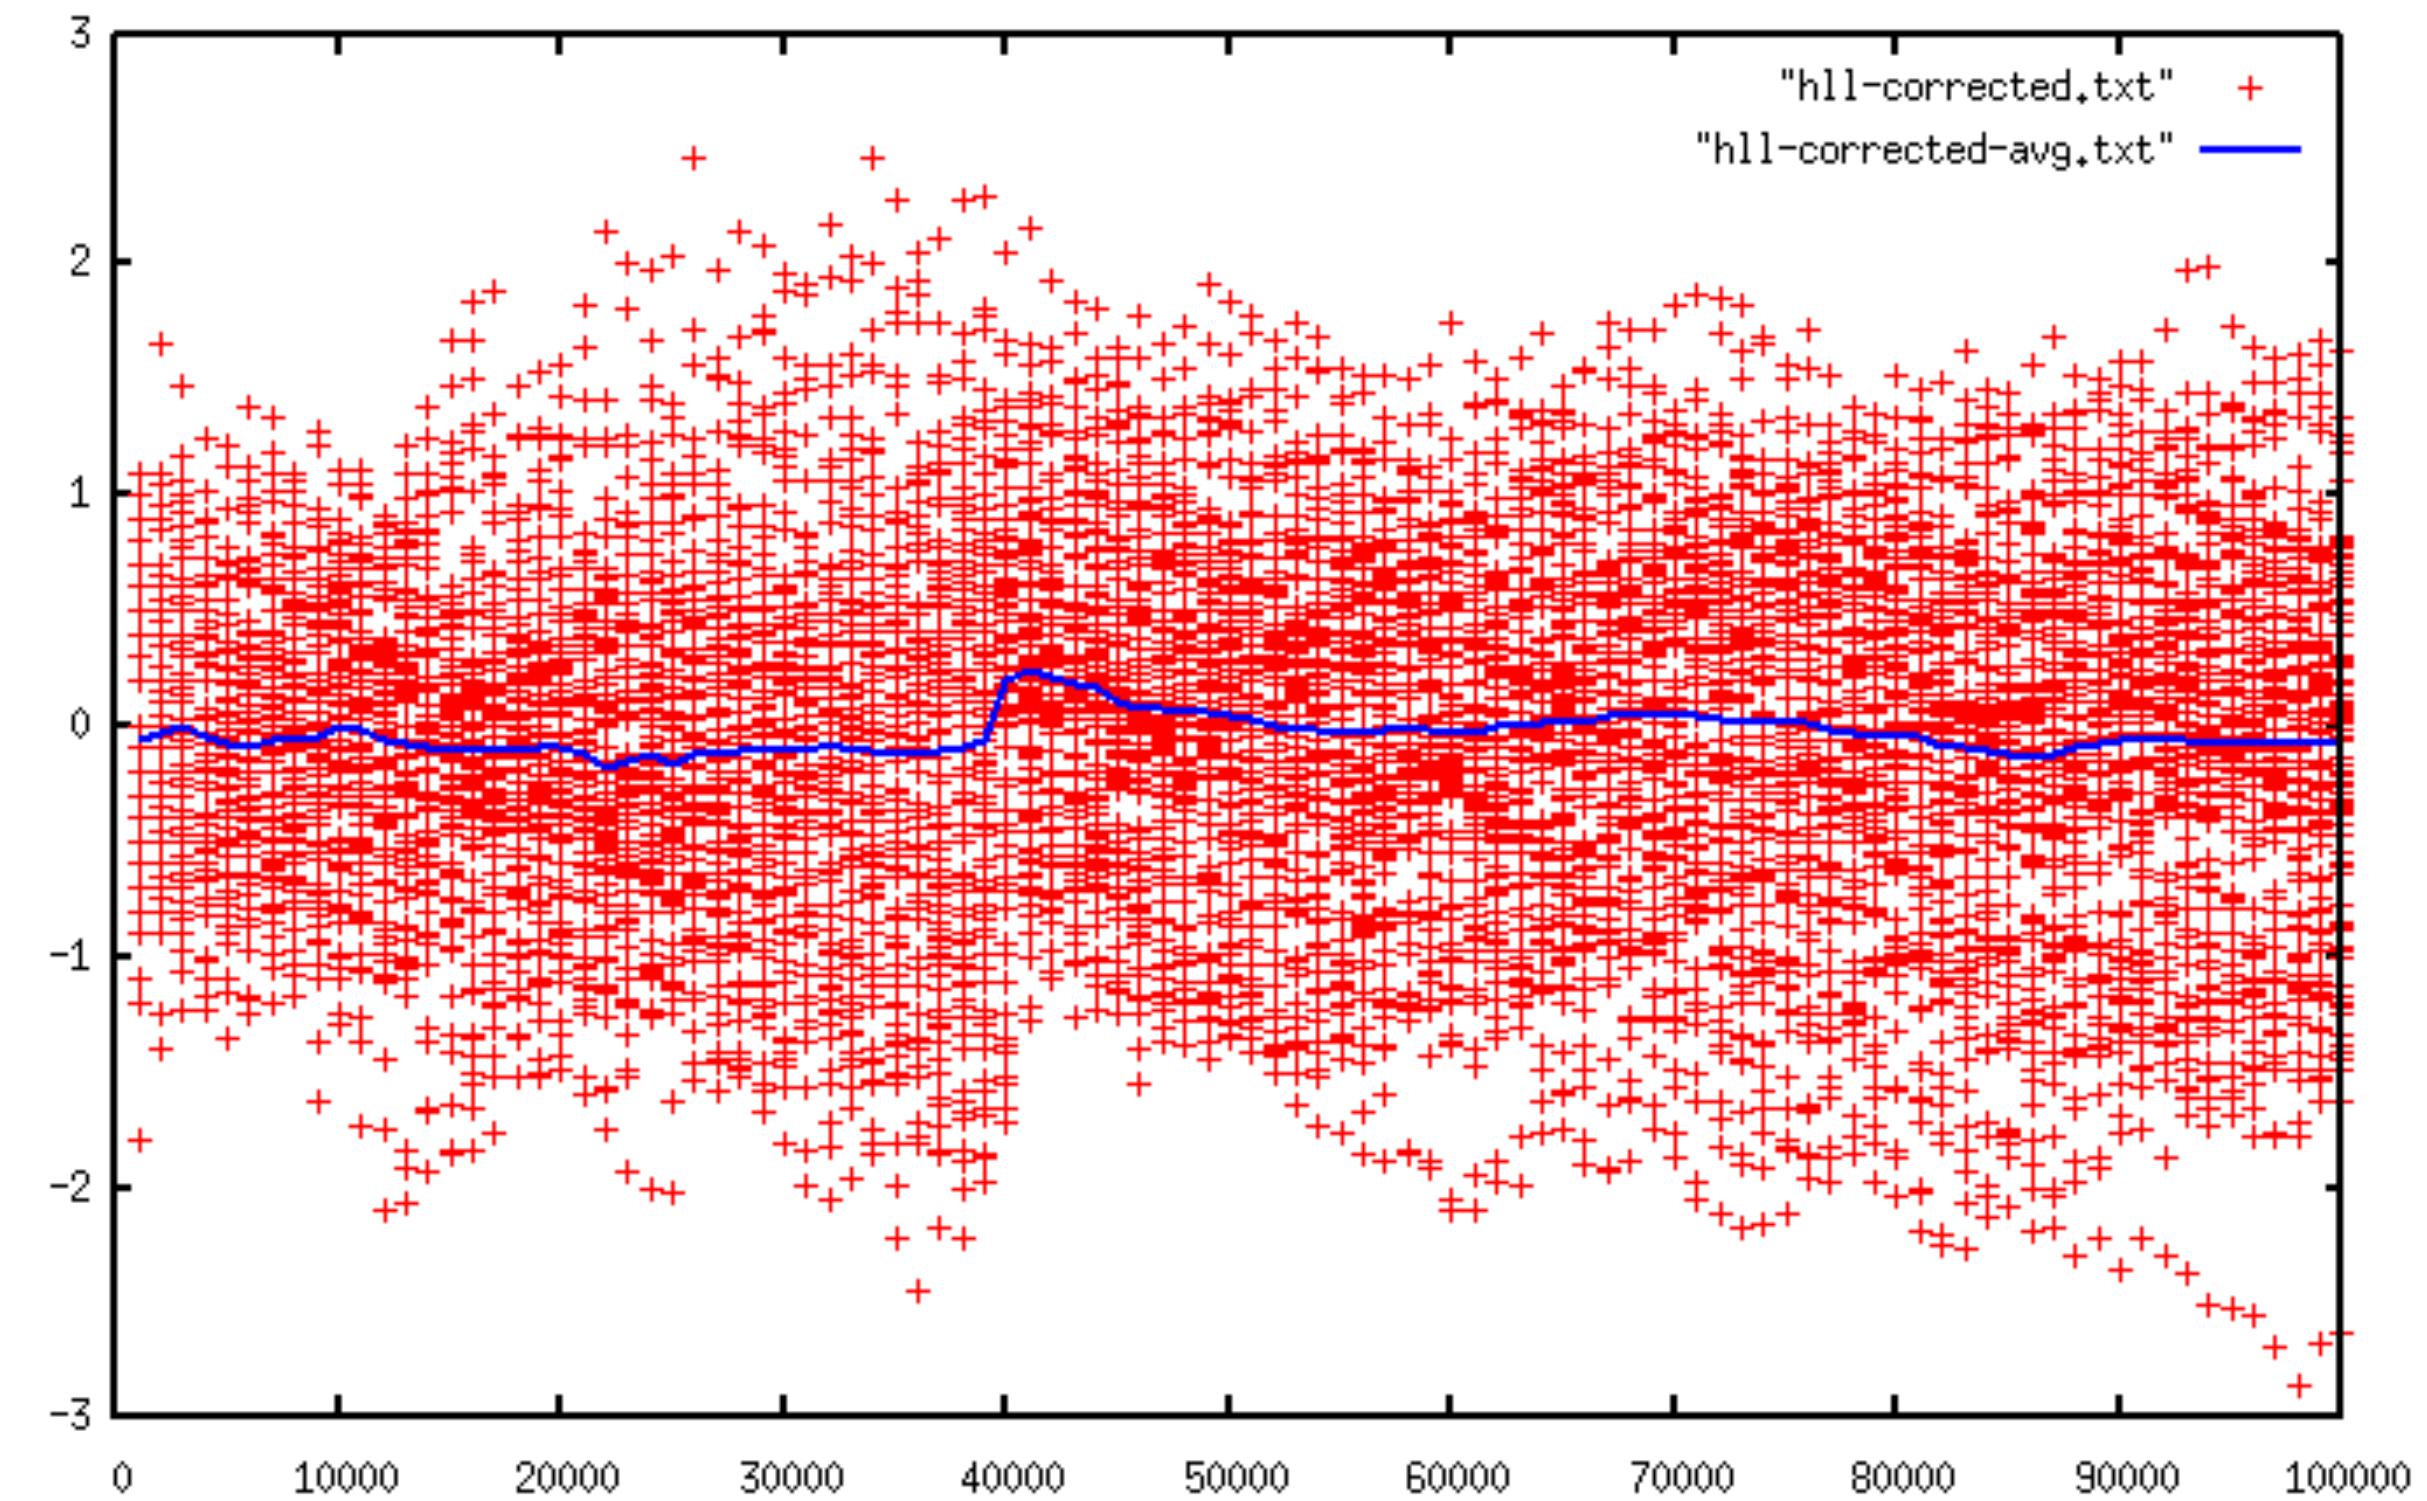
$n_{\text{lin}} \leftarrow m \cdot \log \frac{m}{Z}$   
**if**  $n_{\text{lin}} \leq \chi_m$  **then**  
     $n \leftarrow n_{\text{lin}}$

**return**  $n$

---

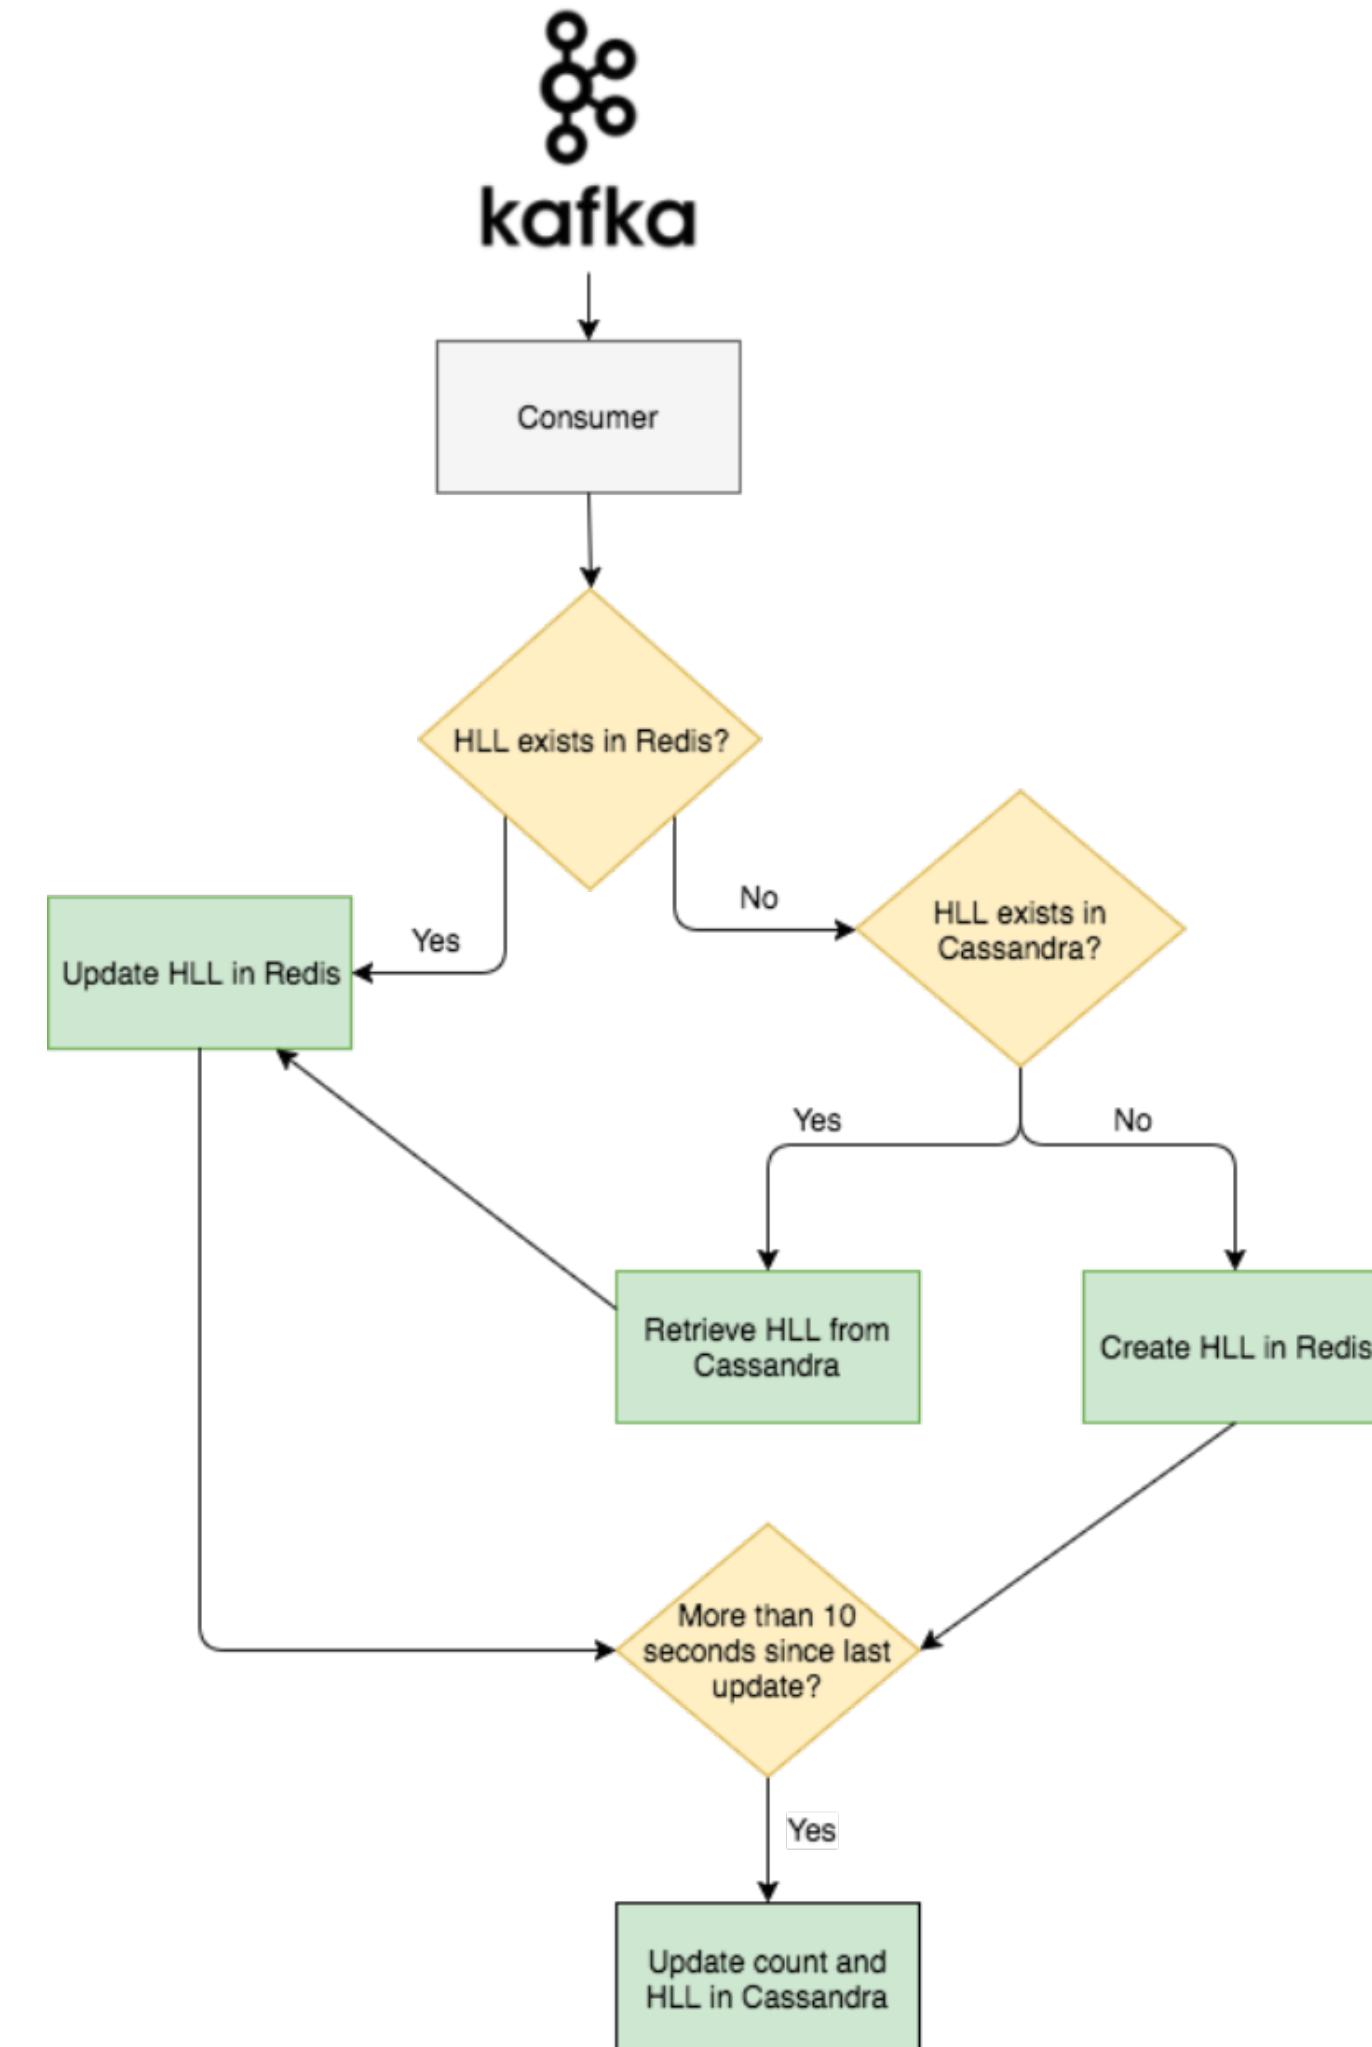
# HyperLogLog - in Redis

- Hash 產生 64 bit int
- 16384 (14 bit) bucket, so the standard error is 0.81%
- 50 bit 用來 counting => 6 bit
- 總共需要 12296 (12k) bytes
- Result
  - $500k * 12 kB = 6 GB$
  - response in real time
  - 0.81 % error rate



# HyperLogLog 實際應用

- Reddit 在計算 Page View 採用 Redis HLL
  - 熱門頁面會有破百萬的不重複用戶瀏覽
  -



# Demo: BigQuery

```
1 SELECT count(distinct user_id) FROM `datamagic-330213.amazingtalker.user_events`
```

按下 Alt+F1 鍵即可查看無障礙工具選項。

查詢結果

工作資訊 結果 JSON 執行作業詳細資料 執行圖 預覽

如要瞭解如何偵錯或最佳化查詢，請參閱說明文件。 [瞭解詳情](#) ↗

經過時間 836 毫秒	消耗的運算單元時間 1 分鐘 13 秒	重組的位元組數 <a href="#">?</a> 218.25 MB	溢出至磁碟的位元組數 <a href="#">?</a> 0 B <a href="#">?</a>
----------------	------------------------	--	--

782131

```
1 select APPROX_COUNT_DISTINCT(user_id) FROM `datamagic-330213.amazingtalker.user_events`
```

```
1 select
2   HLL_COUNT.EXTRACT(HLL_sketch) AS distinct_customers_with_open_invoice
3 From (
4   SELECT HLL_COUNT.INIT(user_id) AS hll_sketch FROM `datamagic-330213.amazingtalker.user_events`
5 )
```

按下 Alt+F1 鍵即可查看無障礙工具選項。

查詢結果

工作資訊 結果 JSON 執行作業詳細資料 執行圖 預覽

如要瞭解如何偵錯或最佳化查詢，請參閱說明文件。 [瞭解詳情](#) ↗

經過時間 1 秒	消耗的運算單元時間 1 分鐘 30 秒	重組的位元組數 <a href="#">?</a> 25.28 MB	溢出至磁碟的位元組數 <a href="#">?</a> 0 B <a href="#">?</a>
-------------	------------------------	---------------------------------------	--

783512 (誤差 0.17 %)

# Demo: Redis

- RedisBloom
  - docker run -p 6380:6379 -p 8001:8001 redis/redis-stack
  - BloomFilter / Cuckoo Filter / t-digest / Count-min Sketch
- HyperLogLog (v2.8.9)
  - PFADD
  - PFCOUNT
- Bloom Filter
  - BF.ADD
  - BF.EXISTS

# Summary

- Probabilistic Data Structure 降低精準度換取 CPU/Memory 資源上的節省
- Hash!
- Membership
  - element 是否出現在 dataset
  - Bloom Filter / Quotient Filter / Cuckoo Filter
- Cardinality
  - dataset 中不重複個數
  - Linear Count / HyperLogLog

